Processamento Digital de Imagens (Digital image processing) : Trabalho 1

> FGA/UnB - Universidade de Brasilia Semestre: 01/2020 Data de entrega: 14/09/2020

Dados do aluno

- Bruna Medeiros da Silva
- Matrícula: 16/0048711

Importando bibliotecas

In [1]:

```
import os
import cv2 as cv
import math
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

1. a

In [2]:

```
img_path = os.path.abspath('images/standard_test_images')
img_name = 'pirate.tif'
file = os.path.join(img_path, img_name)
img = cv.imread(file, 0)
```

In [3]:

```
img.shape
```

Out[3]:

```
(512, 512)
```

In [4]:

```
print('Maximum value: %d\nMinimum value: %d' % (img.max(), img.min()))
```

```
Maximum value: 241
Minimum value: 36
```

1. b

Using Matplotlib

In [5]:

```
fig = plt.imshow(img, cmap = 'gray', vmin = 0, vmax = 255)
plt.colorbar(fig)
```

Out[5]:

```
<matplotlib.colorbar.Colorbar at 0x7f8d54403fd0>
```

Using OpenCV

In [6]:

```
cv.imshow('1.b', img)
cv.waitKey(0)
cv.destroyAllWindows()
```

1. c

1. First way

In [7]:

```
from matplotlib import gridspec

def downsample_512(img):
    original_size = 512
    size = original_size

    img = cv.imread(file, 0)
    fig, axs = plt.subplots(1, 5, figsize=[15, 15])
    fig.subplots_adjust(wspace=0.05)

    axs[0].axis('off')
    axs[0].imshow(img, cmap = 'gray', vmin = 0, vmax = 255, interpolation='none'
)
    axs[0].set_title('%d x %d' % (size, size))

    for ax in axs[1:]:
        img[0 : int(size / 2), 0 : int(size / 2)] = img[0 : size : 2, 0 : size :
2]
        img[int(size / 2) : original_size, :] = 255
        img[:, int(size / 2) : original_size] = 255

        size = int(size / 2)

        ax.axis('off')
        ax.imshow(img, cmap = 'gray', vmin = 0, vmax = 255, interpolation='none'
)
        ax.set_title('%d x %d' % (size, size))


downsample_512(img)
```

2. Second way

In [8]:

```
from matplotlib import gridspec

def downsample_512(img):
    original_size = 512
    size = original_size
    images = {}
    idx = 0

    img = cv.imread(file, 0)
    fig, axs = plt.subplots(1, 5, figsize=[15, 15])
    fig.subplots_adjust(wspace=0.1)

    axs[0].axis('off')
    axs[0].imshow(img, cmap = 'gray', vmin = 0, vmax = 255, interpolation='none'
)
    axs[0].set_title('%d x %d' % (size, size))


    for ax in axs[1:]:
        img = img[0 : size : 2, 0 : size : 2]
        images[idx] = img
#         img[0 : int(size / 2), 0 : int(size / 2)] = img[0 : size : 2, 0 : size
: 2]
#         img[int(size / 2) : original_size, :] = 255
#         img[:, int(size / 2) : original_size] = 255
        idx += 1
        size = int(size / 2)

        ax.axis('off')
        ax.imshow(img, cmap = 'gray', vmin = 0, vmax = 255, interpolation='none'
)
        ax.set_title('%d x %d' % (size, size))
    return images

images = {}
images = downsample_512(img)
```

3. Third way

In [10]:

```
def plot_original(img):
     # dots (pixels) per inch
    dpi = int(os.popen('xdpyinfo | grep -w resolution | grep -Eo "[0-9]{1,}" | h
ead -1').read())

    height, width = img.shape

    # With a screen with x pixels/inch and a image of y pixels
    # we need z = y/x [pixels/pixels/inch] = z inches to represent an image with
its original size
    figsize = width / float(dpi), height / float(dpi)

    fig = plt.figure(figsize=figsize)
    ax  = fig.add_axes([0, 0, 1, 1])
    # Hide axis
    ax.axis('off')

    # Show final image
    ax.imshow(img, cmap='gray')

    plt.show()
```

In [11]:

```
from matplotlib import gridspec

def downsample_512(img):
    original_size = 512
    size = original_size

    for ax in range(5):
        img = img[0 : size : 2, 0 : size : 2]
        size = int(size / 2)
        plot_original(img)

downsample_512(img)
```

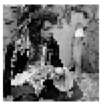

1. d

Nearest Neighbours

Método usado para interpolação, regreção e classificação que se utiliza da teoria de que amostras espacialmente próximas tendem a conter informações parecidas.

Com isso, o método de interpolação dos k vizinhos mais próximos em imagens 2D utiliza o valor dos k pixels mais próximos (com uma menor distância espacial) para definir o valor do pixel em questão.

Essa distância utilizada no cálculo é a distância euclidiana.

Recomenda-se utilizar valores de k **ímpares**, para evitar "empates" no momento de definir o valor adequado. No geral, são utilizados valores de $k = \sqrt{N}$ ou $k = \log N$, onde N é o número de amostras que você possui.

Processo para definição de índices e valores

> Esse método de obtençao dos índices corretos para o algoritimo de k vizinhos mais próximos pode ser encontrado [aqui (https://www.imageeprocessing.com/2017/11/nearest-neighbor-interpolation.html)](https://www.imageeprocessing.com/2017/11/nearest-neighbor-interpolation.html)

In [ ]:

```
"""
# O processo pode ser explicado da seguinte forma:

1. Consideremos que passaremos de uma imagem M x M para uma imagem N x N, onde M
< N;

2. Como teremos que preencher cada pixel com o valor do pixel mais próximo, pode
mos visualizar que isso formará conjuntos de pixels iguais (no caso de k = 1)

    2.1. Ex.: Upsample de 2 níveis   1 2  -->  1   1 2   2
             - 2x2 -> 4x4            3 4       1 **1 2** 2
                                               3 **3 4** 4
                                               3   3 4   4

3. Com isso, notamos que foi feita uma "divisão" e cada pixel foi utilizado 2 ve
zes/coluna e 2 vezes/linha

    3.1. Esse valor pode ser obtido pela divisão das dimensões (4/2 = 2)

4. Sabendo disso, para encontrar o index correto, devemos fazer uma análise linh
a por linha.

    4.1. Visualizando os índices de cada coluna: |0 1| (Original) |0 1 2 3| (int
erpolada)

    4.2. Se fôssemos copiar o índice de cada valor da primeira coluna, ficaríamo
s com |0 0 1 1| -> |1 1 2 2|

5. Observando esses detalhes, podemos notar um padrão, onde |0/2=0 1/2=0 2/2=1
 3/2=1| (valores arrendondados para baixo)

    5.1. O mesmo pode ser feito com as colunas:

    (valores) |     (idx original)     |      (arredondamento)
              1                        0                          0/2=0
              1          --->          0           --->           1/2=0
              3                        1                          2/2=1
              3                        1                          3/2=1

6. Com isso obtemos que $ valorImagem(idxPixel) = valorImagemOriginal(\frac{idxP
ixel}{\frac{N}{M}}) $.

7. Após aplicarmos isso em todas as linhas/colunas, deveremos aplicar o mesmo pr
ocesso em todas as colunas/linhas da imagem

7.1. Aplicando nas linhas:

|1 2|   -->    |pixel(0/2=0) pixel(1/2=0) pixel(2/2=1) pixel(3/2=1)|   -->    |1
1 2 2|

|3 4|   -->    |pixel(0/2=0) pixel(1/2=0) pixel(2/2=1) pixel(3/2=1)|   -->    |3
3 4 4|

    - Com isso obtemos uma parte do resultado:

    |1 1 2 2|
    |3 3 4 4|

7.2. Aplicando o processo nas colunas dessa nova tabela:
```

```
1              |           2

3              |           4

|              |           |
|              |           |
v                          v

pixel(0/2=0)    |     pixel(0/2=0)
pixel(1/2=0)    |     pixel(1/2=0)
pixel(2/2=1)    |     pixel(2/2=1)
pixel(3/2=1)    |     pixel(3/2=1)


|                          |
|                          |
v                          v

1                          2
1                          2
3                          4
3                          4


8. Por fim, teremos o resultado


1 1 2 2
1 1 2 2
3 3 4 4
3 3 4 4
"""
```

1. e

In [12]:

```
def knn_512(images):
    n_images = len(images)
    new_images = {}
    final_size = 512

    plot_row = 0
    plot_column = 0

    fig, axs = plt.subplots(2, round(n_images/2), figsize=[5, 5])
    fig.subplots_adjust(wspace=0.1)

    for idx in range(n_images):
        initial_size = len(images[idx])
        space = final_size / initial_size
        new_images_row = np.zeros([initial_size, final_size])
        new_images[idx] = np.zeros([final_size, final_size])

        new_images_idx = np.zeros([final_size, final_size])
        for row in range(initial_size):
            for column in range(final_size):
                new_images_idx[row][column] = int(column / space)
                new_images_row[row][column] = images[idx][row][int(new_images_id
x[row][column])]

        new_images_idx = np.zeros([final_size, final_size])
        for column in range(final_size):
            for row in range(final_size):
                new_images_idx[row][column] = int(row / space)
                new_images[idx][row][column] = new_images_row[int(new_images_idx
[row][column])][column]

        axs[plot_row][plot_column].axis('off')
        axs[plot_row][plot_column].imshow(new_images[idx], cmap = 'gray', vmin =
0, vmax = 255, interpolation='none')
        axs[plot_row][plot_column].set_title('%d x %d' % (initial_size, initial_
size))

        plot_column += 1
        if(plot_column == round(n_images/2)):
            plot_row += 1
            plot_column = 0

    return new_images;

new_images = knn_512(images)
```

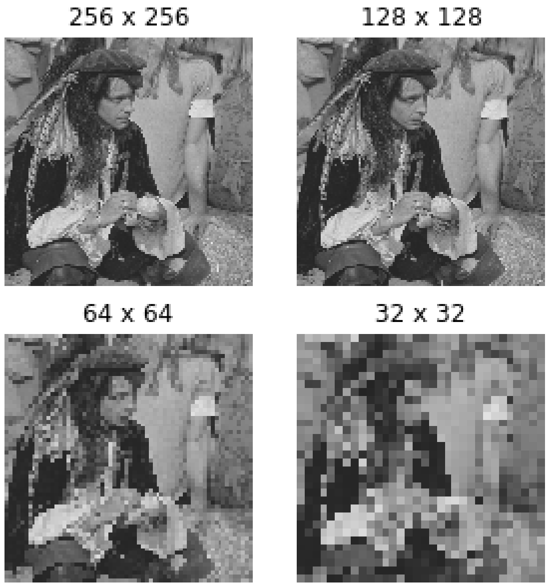
256 x 256
128 x 128
64 x 64
32 x 32

In [ ]:

```
"""
Imagem original (exemplo)
  1 2
  3 4

## Passando para uma imagem de tamanho 8

space = 8/2 = 4
de coluna em coluna:

### 1a coluna
- Antiga imagem:

        1
        3

- posições na nova imagem:
    0                        0                                                1
    1                        0                                                1
    2                        0                                                1
    3                        0                                                1
    4          /4    =       1          ---> pegando os valores:              3
    5                        1                                                3
    6                        1                                                3
    7                        1                                                3

### 2a coluna
- Antiga imagem:

        2
        4

- posições na nova imagem:
    0                        0                                                2
    1                        0                                                2
    2                        0                                                2
    3                        0                                                2
    4          /4    =       1          ---> pegando os valores:              4
    5                        1                                                4
    6                        1                                                4
    7                        1                                                4


### Até agora temos ...

1     2
1     2
1     2
1     2
3     4
3     4
3     4
3     4

### 1a à 4a linha
- Agora o mesmo processo é aplicado nas linhas que já foram iteradas, seguindo o
mesmo passo a passo feito com as colunas:

- Imagem original
```

```
        1     2

- Imagem interpolada

    - Posições da nova imagem:
                0 1 2 3 4 5 6 7

    - dividindo pelo space e arrendondando:
                0 0 0 0 1 1 1 1

    - pegando os valores dos indices indicados:
                1 1 1 1 2 2 2 2


### 5a à 8a linha

- Imagem original

        3     4

- Imagem interpolada

    - Posições da nova imagem:
                0 1 2 3 4 5 6 7

    - dividindo pelo space e arrendondando:
                0 0 0 0 1 1 1 1

    - pegando os valores dos indices indicados:
                3 3 3 3 4 4 4 4

## Resultado final

| 1 1 1 1 2 2 2 2 |

| 1 1 1 1 2 2 2 2 |

| 1 1 1 1 2 2 2 2 |

| 1 1 1 1 2 2 2 2 |

| 3 3 3 3 4 4 4 4 |

| 3 3 3 3 4 4 4 4 |

| 3 3 3 3 4 4 4 4 |

| 3 3 3 3 4 4 4 4 |
"""
```

1.f. Interpolação Bilinear

[Fonte: SuperComputer's Blog (https://chao-ji.github.io/jekyll/update/2018/07/19/BilinearResize.html#:~:text=Like%20linearly%20resizing%20a%201,and%](https://chao-ji.github.io/jekyll/update/2018/07/19/BilinearResize.html#:~:text=Like%20linearly%20resizing%20a%201,and%)

Essa forma de interpolação pode ser aplicada em imagens (ou array) de duas dimensões (como x e y, por exemplo)

Para aplicar essa técnica são feitas duas interpolações lineares em sequência: aplica-se primeiro em uma das dimensões e, no resultado obtido, aplica-se na outra dimensão.

Interpolação linear

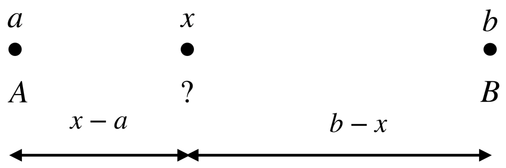

A interpolação linear utiliza, se certa forma, uma média ponderada dos valores dos pixels mais próximos. Os pesos dessa média serão definidos pela distância total entre esses pixels.

Exemplo:

In [ ]:

```
"""
        10m
<-------------------->
   2m        8m
  <-->   <--------->
*a     *x           *b

Se nós queremos saber o valor do ponto x, ele será: x = (a * 2 / 10) + (b * 8 / 10)

Utilisando termos mais genéricos, poderíamos considerar que a fórmula para o cálculo seria

X = A * (x - a)    +  B * (b - x)
        -------           -------
        (b - a)           (b - a)

Onde:

a - Posição do ponto mais próximo à esquerda
b - Posição do ponto mais próximo à direita
x - Ponto ao qual temos que atribuir um valor

A = valor do ponto em a
B = valor do ponto em b
X = valor do ponto em x
"""
```

Interpolação bilinear

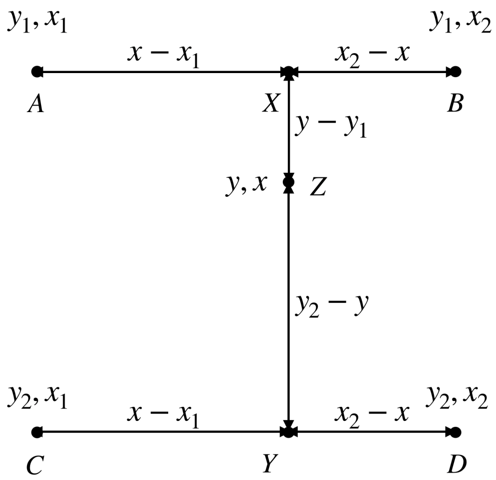

Considerando que o processo visto acima poderá ser feito tanto em uma coluna quanto em uma linha, a interpolação bilinear é feita do seguinte modo:

1. Primeiro, considerando apenas a linha de cima da imagem e ignorando todo o resto, podemos fazer uma interpolação linear no eixo x de forma que:

$$X = A \cdot \frac{x - x_1}{x_2 - x_1} + B \cdot \frac{x_2 - x}{x_2 - x_1}$$

1. Fazendo o mesmo na linha de baixo:

$$Y = C \cdot \frac{x - x_1}{x_2 - x_1} + D \cdot \frac{x_2 - x}{x_2 - x_1}$$

1. Para encontrar Z, agora que temos os valores de X e Y, fazemos o mesmo procedimento no intervalo vertical entre eles:

$$Z = X \cdot \frac{y - y_1}{y_2 - y_1} + Y \cdot \frac{y_2 - y}{y_2 - y_1}$$

1. Observações:
   - Esse processo também pode ser feito de forma "direta" se substituirmos os valores de X e Y no cálculo de Z;
   - Nesse caso, considera-se que os eixo x e y crescem da esquerda pra direita e de cima para baixo, respectivamente.

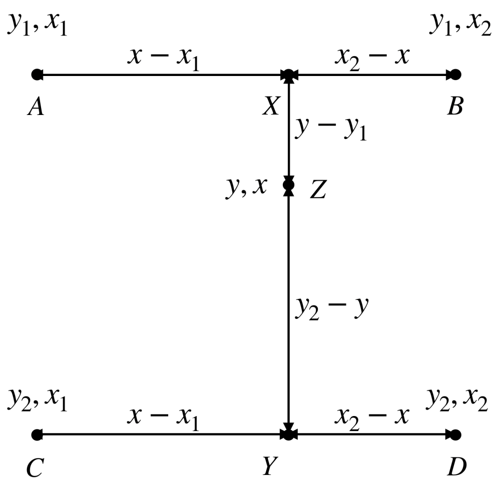

1. g

In [13]:

```
def bilinear_512(images):
    n_images = len(images)
    new_images = {}
    final_size = 512

    plot_row = 0
    plot_column = 0

    fig, axs = plt.subplots(2, round(n_images/2), figsize=[5, 5])
    fig.subplots_adjust(wspace=0.1)

    for img in range(n_images):
        initial_size = len(images[img])
        space = final_size / initial_size
        new_images[img] = np.zeros([final_size, final_size])

        for row in range(final_size):
            percent_row = row/space - math.floor(row/space)
            idx_row = math.ceil(row/space) if row/space < (initial_size - 1) els
e math.floor(row/space)

            for col in range(final_size):
                percent_col = col/space - math.floor(col/space)
                idx_col = math.ceil(col/space) if col/space < (initial_size - 1)
else math.floor(col/space)

                x_floor = images[img][math.floor(row/space)][math.floor(col/spac
e)]
                x_ceil  = images[img][math.floor(row/space)][idx_col]
                x = ((1 - percent_col) * x_floor) + (percent_col * x_ceil)

                y_floor = images[img][idx_row][math.floor(col/space)]
                y_ceil  = images[img][idx_row][idx_col]
                y = ((1 - percent_col) * y_floor) + (percent_col * y_ceil)

                new_images[img][row][col] = ((1 - percent_row) * x) + ((percent_
row) * y)


        axs[plot_row][plot_column].axis('off')
        axs[plot_row][plot_column].imshow(new_images[img], cmap = 'gray', vmin =
0, vmax = 255, interpolation='none')
        axs[plot_row][plot_column].set_title('%d x %d' % (initial_size, initial_
size))

        plot_column += 1
        if(plot_column == round(n_images/2)):
            plot_row += 1
            plot_column = 0

    return new_images;

new_images = bilinear_512(images)
```

1. h

PSNR

PSNR é a sigla em inglês do termo *Peak Signal-to-Noise Ratio* (relação sinal-ruído de pico). Esse é uma medida que se utiliza do erro médio quadrático (MSE - *Mean squared error*) para calcular "a relação entre a máxima energia de um sinal e o ruído que afeta sua representação fidedigna".

O PSNR geralmente é dado utilizando escala logarítima, em decibéis.

A fórmula para obtenção desse valor é:

$$PSNR = 10 \cdot \log_{10}\left(\frac{MAX_I^2}{MSE}\right) = 20 \cdot \log_{10}\left(\frac{MAX_I}{\sqrt{MSE}}\right),$$

Onde:

$$MSE = \frac{1}{MN}\sum_{i=0}^{M-1}\sum_{j=0}^{N-1}||I(i,j) - K(i,j)||^2$$

In [14]:

```
def img_psnr(image, original_image):
    M = original_image.shape[0]
    N = original_image.shape[1]
    mse = 0

    for i in range(M):
        for j in range(N):
            mse = mse + abs(original_image[i][j] - image[i][j])**2

    mse = mse/(M * N)
    PSNR = 20 * math.log10(255/math.sqrt(mse))
    return PSNR
```

Imagens reconstruídas usando KNN

In [15]:

```
images_knn = knn_512(images)
```

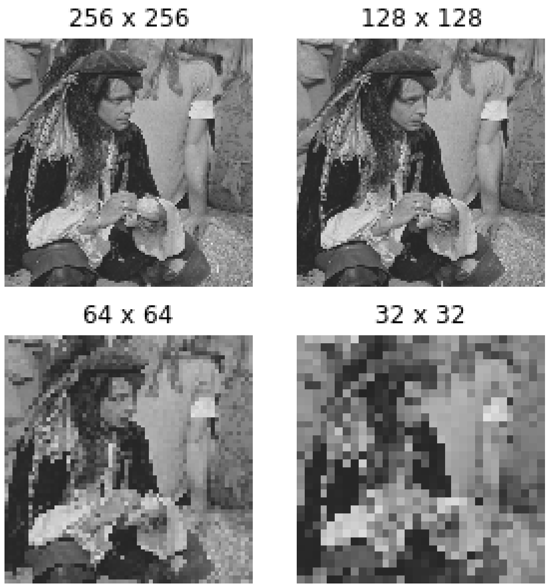

Imagens reconstruídas utilizando interpolação bilinear

In [16]:

```
images_bilinear = bilinear_512(images)
```

In [17]:

```
dim = [256, 128, 64, 32]
psnr_df = pd.DataFrame(columns = ['size', 'psnr_knn_db', 'psnr_bilinear_db'])
for i in range(len(images_knn)):
    psnr_knn = img_psnr(images_knn[i], img)
    psnr_bilinear = img_psnr(images_bilinear[i], img)
    psnr_df = psnr_df.append({'size': '%d x %d'% (dim[i], dim[i]),
                              'psnr_knn_db': '%.2f'% psnr_knn,
                              'psnr_bilinear_db': '%.2f'% psnr_bilinear},
                              ignore_index=True)
psnr_df
```

Out[17]:

	size	psnr_knn_db	psnr_bilinear_db
0	256 x 256	26.52	30.38
1	128 x 128	21.76	25.75
2	64 x 64	18.71	22.66
3	32 x 32	16.37	20.04

1.i.

Utilizando a psnr como métrica base, pode-se dizer que, para a imagem utilizada, o método de amplificação da imagem por meio interpolação bilinear se mostrou muito mais fiel às imagens originais (em todos os casos aqui experimentados) do que o método do vizinho mais próximo (knn)

1.j.

Se fôssemos fazer uma conversão de uma linha que vai de 0 a 255 para outra linha que vai de 0 a L, poderíamos seguir o seguinte raciocínio:

$y = ax + b$, onde

- y é o valor equivalente na linha L
- x é o valor original
- a é o coeficiente angular
- b é o coeficiente linear

Sabendo que o 0 será 0 em qualquer uma das retas:

$0 = a \cdot 0 + b$. Logo, $b = 0$

Convertendo o ponto 255 para o ponto L: $L = a \cdot 255$. Logo, $a = \frac{L}{255}$ e $\frac{1}{a} = \frac{255}{L}$.

Esse valor $\frac{1}{a}$ será o valor pelo qual dividiremos os valores dos pixels originais para obter o pixel dentro dos demais ranges propostos

- 16 -> 4 bits,
- 4 -> 2 bits e
- 2 -> 1 bit.

In [18]:

```
def img_scale(image):
    n_images = 4
    images = {}
    fig, axs = plt.subplots(1, n_images, figsize=[20, 20])
    fig.subplots_adjust(wspace=0.1)

    for idx in range(n_images):
        ratio = 255/(2**(2**idx) - 1)
        images[idx] = np.round(np.divide(image, ratio))

        axs[(n_images - 1) - idx].axis('off')
        axs[(n_images - 1) - idx].imshow(images[idx], cmap = 'gray', interpolati
on='none')
        axs[(n_images - 1) - idx].set_title('%d bits' % (2**idx))

img_scale(img)
```